

Adversarial Learning for Zero-shot Domain Adaptation

Yuting Lin, Kokusai Kogyo Co., Ltd.(国際航業)

書籍情報

- タイトル
 - Adversarial Learning for Zero-shot Domain Adaptation
- 著者
 - Jinghua Wang and Jianmin Jiang
 - Shenzhen University
- ECCV2020 (poster) に採択
- ICCV2019にも、Zero-Shot Domain Adaptation (ZSDA) の論文を投稿した
(Conditional Coupled Generative Adversarial Networks for Zero-Shot Domain Adaptation)

概要

- 手法の概要：
 - target domainがないzero-shot domain adaptationタスクにおいて、domainと同じだが、他種別のデータで学習したdomain shiftを適用してtarget domainのデータを生成する手法
- 提案手法のポイント
 - target/source domainと同じdomainの別の画像データから、domain shiftを学習
 - domain shiftを用いてtarget domainの画像を生成する
 - Co-training方策で、性能を向上する

問題定義

- ToI(Task of Interest)において、target domainのデータが存在しない
 - ToIのdomainと同じかつ、取得できる画像から、IrT(irrelevant task)の学習より、domain shiftを取得する

- データの表記:

ToI source: X_S^α

ToI target: X_t^α (生成対象)

IrT source: X_S^β

IrT target: X_t^β




Fig. 1. An intuitive example of ZSDA (best viewed in color). The *ToI* is digit image analysis and the *IrT* is letter image analysis. The source domain consists of gray scale images and the target domain consists of color images. In order to learn the model for the unseen *MNIST-M* (i.e., target-domain data in *ToI*), we first learn the domain shift based on the dual-domain samples in the *IrT*, then transfer it to the *ToI*.

既往研究

- Zero-Shot Domain Adaptationは3つの流派がある

- ① domain-invariant featuresを抽出することで、domainが異なっても認識できるモデルを学習する
 - Domain-invariant component analysis (DICA)[1]、multi-task autoencoder (MTAE)[2]、Conditional invariant deep domain generalization (CIDDG)[3]、deep domain generalization framework (DDG) [4]
- ② domain情報は、潜在空間上のdomainに依存しないcommon factorとdomain specific factorにより決定されると仮定する。common factorが分かれば、unseen domainに適応できる[5], [6], [7], [8]
- ③ target/source domainの関係性を、別のタスクにより学習し、データに適応する
 - Zero-shot deep domain adaptation (ZDDA) [9]、CoCoGAN[10]

[1] Muandet, K., Balduzzi, D., Schölkopf, B.: Domain generalization via invariant feature representation. In: ICML (2013)

[2] Ghifary, M., Kleijn, W.B., Zhang, M., Balduzzi, D.: Domain generalization for object recognition with multi-task autoencoders. In: ICCV (2015)

[3] Li, Y., Tian, X., Gong, M., Liu, Y., Liu, T., Zhang, K., Tao, D.: Deep domain generalization via conditional invariant adversarial networks. In: ECCV (2018)

[4] Ding, Z., Fu, Y.: Deep domain generalization with structured low-rank constraint. IEEE Transactions on Image Processing 27(1), 304–313 (2018)

[5] Khosla, A., Zhou, T., Malisiewicz, T., Efros, A.A., Torralba, A.: Undoing the damage of dataset bias. In: ECCV (2012)

[6] Li, D., Yang, Y., Song, Y.Z., Hospedales, T.M.: Deeper, broader and artier domain generalization. In: ICCV (2017)

[7] Yang, Y., Hospedales, T.: Zero-shot domain adaptation via kernel regression on the grassmannian (2015). <https://doi.org/10.5244/C.29.DIFFCV.1>


[8] Kodirov, E., Xiang, T., Fu, Z., Gong, S.: Unsupervised domain adaptation for zero-shot learning. In: ICCV (2015)

[9] Peng, K.C., Wu, Z., Ernst, J.: Zero-shot deep domain adaptation. In: ECCV (2018)

[10] Wang, J., Jiang, J.: Conditional coupled generative adversarial networks for zero- shot domain adaptation. In: ICCV (2019)


既往研究

- Coupled Generative Adversarial Networks (CoGAN)[11]
 - 生成器と識別器の一部分のパラメータを共有する2つのGANを持つ
 - 異なるドメインの画像を同時に生成する
 - 提案手法は、CoGANの構造に基づく




提案手法の概要

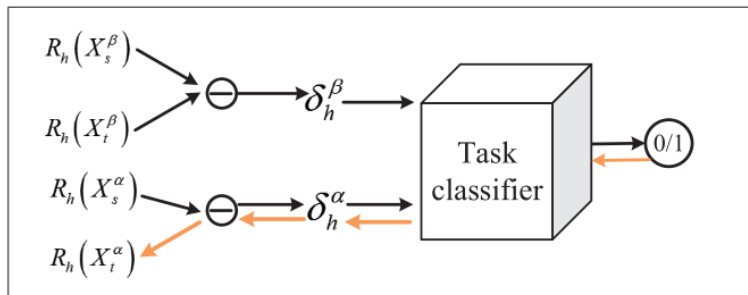
- CoGAN-IrTにより、domain shiftを取得
- CoGAN-ToIにより、取得したdomain shiftを適用すると同時に、するtarget domainを生成
- Co-trainingにより、target domainデータの生成に制約をかける




(a) CoGAN-IrT for IrT



(b) CoGAN-ToI for ToI




(c) Task classifier for shift transferring




(d) Co-training classifiers

提案手法

- CoGAN-IrT:
 - ペア画像を入力とし、target/source domain間のjoint分布を学習
 - 潜在空間上の特徴の違いを、domain shiftとなる
- CoGAN-ToI:
 - domain shiftを適用するため、2つ制約をかける



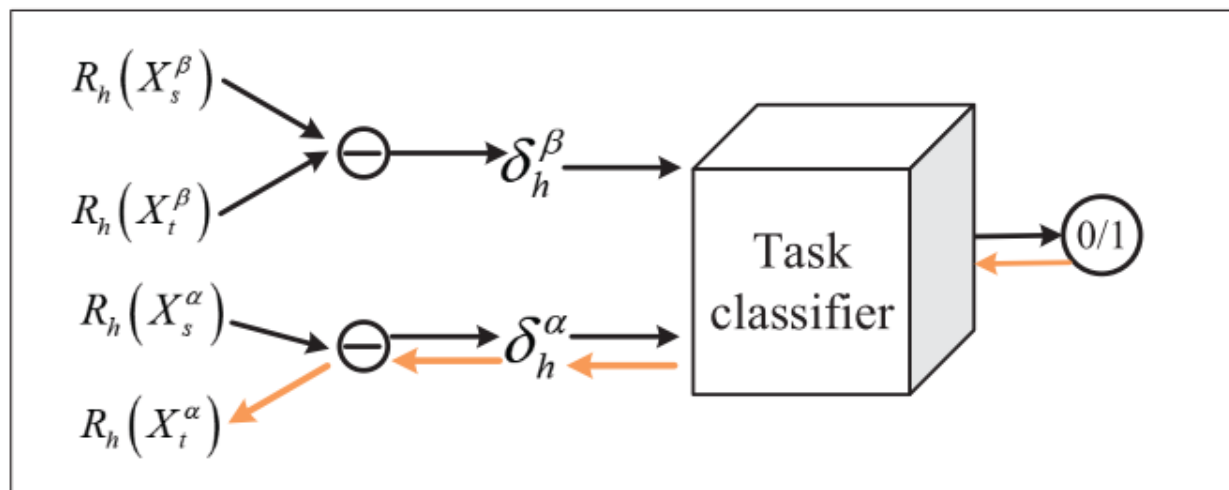
(a) CoGAN-IrT for IrT



(b) CoGAN-ToI for ToI

提案手法

- 1つ目の制約: Domain shiftが正しく適用されているか
 - 識別器の共有部 (high-level) の表現の element-wise 差分 ($\delta_h^\beta = R_h(x_t^\beta) \ominus R_h(x_s^\beta)$) を domain shift とする
 - CoGAN-IrT と CoGAN-ToI における domain shift は一緒であるべき
 - ✓ 分類器で、 δ_h^β と δ_h^α を分類する




(c) Task classifier for shift transferring

提案手法

- 2つ目の制約: Co-training classifiers

- 2つclassifierのconsistencyを利用して、CoGAN-ToIの学習に制約をかける
- 目的: 2つclassifierは異なるパラメータを持ち、違う視点から入力データを分析する
- loss $L(clf_1, clf_2) = \lambda_w L_w(w_1, w_2) + \lambda_{acc} L_{cls}(X_s^\alpha) - \lambda_{con} L_{con}(X^\beta) + \lambda_{diff} L_{diff}(\tilde{X})$
- 入力: $R_l(x_s^\beta)$, $R_l(x_t^\beta)$, $R_l(x_s^\alpha)$
- L_w : classifierの類似度を測る
- L_{cls} : x_s^α の分類loss
- L_{con} : x_s^β と x_t^β を入力とした際のconsistency
- L_{diff} : 以外のサンプルを入力した際のconsistency
- 結果、classifiersは入力がsource/target domainに属するのかを判別できるようになる。CoGAN-ToIを学習する際のsupervisory signalとなる



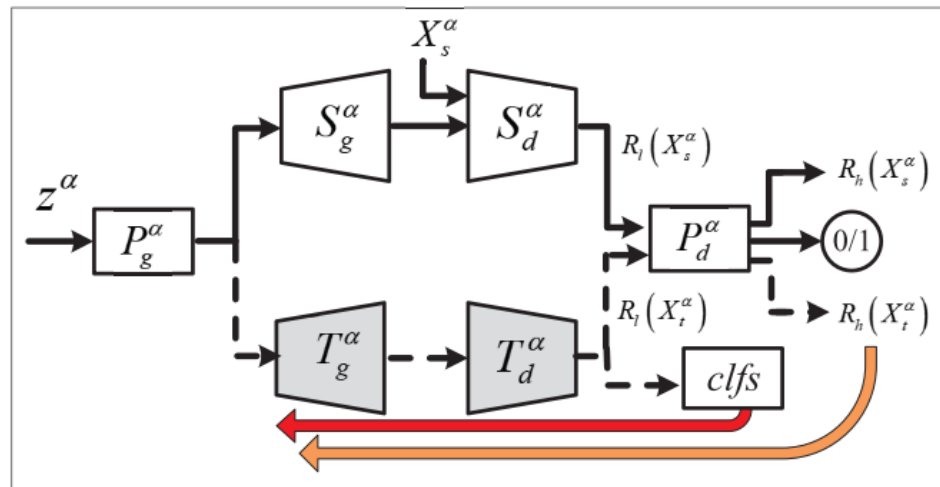
(d) Co-training classifiers

提案手法

- CoGAN-ToIの学習

- 3つの制約で学習する: ① x_s^α のdomainに従って画像生成、②domain shift、③Co-training classifiers
- CoGANと異なり、別々で学習する
- Low-level部分のパラメータは、CoGAN-IrTで学習したもので初期化する

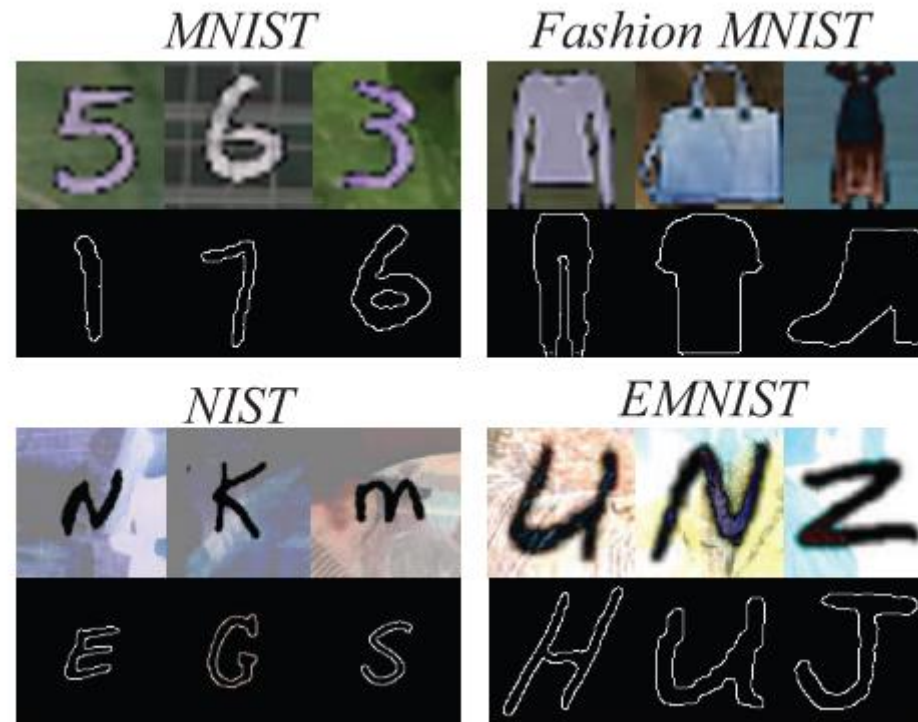
$$V(P_g^\alpha, T_g^\alpha, T_d^\alpha, P_d^\alpha) \equiv \lambda_{con}^\alpha \sum_{x_t^\alpha = g_t^\alpha(z^\alpha)} v_1(x_t^\alpha) \cdot v_2(x_t^\alpha) - L_{clf}(\delta_h^\alpha, \delta_h^\beta),$$



(b) CoGAN-ToI for ToI

実験

- 検証データセット:
 - MNIST (D_M), Fashion-MNIST (D_F), NIST (D_N), EMNIST (D_E)
- 検証domain:
 - gray domain (G-dom), colored domain (C-dom), edge domain (E-dom), negative domain (N-dom)



実験

- 既存手法より、高い精度を達した

Table 1. The accuracy of different methods with $(source, target) = (G-dom, C-dom)$

ToI IrT	D_M			D_F			D_N		D_E	
	D_F	D_N	D_E	D_M	D_N	D_E	D_M	D_F	D_M	D_F
ZDDA	73.2	92.0	94.8	51.6	43.9	65.3	34.3	21.9	71.2	47.0
CoCoGAN	78.1	92.4	95.6	56.8	56.7	66.8	41.0	44.9	75.0	54.8
ZDDA _{dc}	69.3	79.6	80.7	50.6	42.4	62.0	29.1	20.2	49.8	46.5
CTCC	68.5	74.9	77.6	42.0	52.9	60.9	37.0	43.6	47.3	45.2
Ours	81.2	93.3	95.0	57.4	58.7	62.0	44.6	45.5	72.4	58.9

Table 2. The accuracy of different methods with $(source, target) = (G-dom, E-dom)$

ToI IrT	D_M			D_F			D_N		D_E	
	D_F	D_N	D_E	D_M	D_N	D_E	D_M	D_F	D_M	D_F
ZDDA	72.5	91.5	93.2	54.1	54.0	65.8	42.3	28.4	73.6	50.7
CoCoGAN	79.6	94.9	95.4	61.5	57.5	71.0	48.0	36.3	77.9	58.6
ZDDA _{dc}	66.5	83.3	84.7	49.3	50.4	58.0	42.2	31.6	65.0	41.2
CTCC	65.5	73.9	80.5	44.0	40.8	37.3	40.0	31.4	57.7	48.2
Ours	81.4	93.5	96.3	63.2	58.7	72.4	49.9	38.6	78.2	61.1

Table 3. The accuracy of different methods with $(source, target) = (C-dom, G-dom)$

ToI IrT	D_M			D_F			D_N		D_E	
	D_F	D_N	D_E	D_M	D_N	D_E	D_M	D_F	D_M	D_F
ZDDA	67.4	85.7	87.6	55.1	49.2	59.5	39.6	23.7	75.5	52.0
CoCoGAN	73.2	89.6	94.7	61.1	50.7	70.2	47.5	57.7	80.2	67.4
ZDDA _{dc}	61.5	76.7	79.9	51.2	46.1	53.4	31.3	20.4	61.2	42.2
CTCC	62.1	76.9	68.6	47.2	45.6	57.6	27.5	33.6	58.0	49.9
Ours	73.7	91.0	93.4	62.4	53.5	71.5	50.6	58.1	83.5	70.9

Table 4. The accuracy of different methods with $(source, target) = (N-dom, G-dom)$

ToI IrT	D_M			D_F			D_N		D_E	
	D_F	D_N	D_E	D_M	D_N	D_E	D_M	D_F	D_M	D_F
ZDDA	78.5	90.7	87.6	56.6	57.1	67.1	34.1	39.5	67.7	45.5
CoCoGAN	80.1	92.8	93.6	63.4	61.0	72.8	47.0	43.9	78.8	58.4
ZDDA _{dc}	68.4	79.8	82.5	48.1	46.2	64.6	28.6	34.4	61.8	36.2
CTCC	68.4	80.0	80.2	50.1	55.1	61.3	37.6	33.9	56.1	33.9
Ours	82.6	94.6	95.8	67.0	68.2	77.9	51.1	44.2	79.7	62.2

実験

- 検証データセット:

- Office-Home, Art (Ar), Clipart (Cl), Product (Pr), and Real-world (Rw)

Table 5. The accuracy of different methods on Office-Home

Source	<i>Ar</i>			<i>Cl</i>			<i>Pr</i>			<i>Rw</i>		
Target	<i>Cl</i>	<i>Pr</i>	<i>Rw</i>	<i>Ar</i>	<i>Pr</i>	<i>Rw</i>	<i>Ar</i>	<i>Cl</i>	<i>Rw</i>	<i>Ar</i>	<i>Cl</i>	<i>Pr</i>
ZDDA _{dc}	53.2	61.4	68.8	67.4	57.0	68.4	60.9	40.6	62.4	68.1	43.4	50.3
CoCoGAN	62.2	69.5	74.5	66.7	74.0	66.4	57.6	53.4	71.7	69.2	51.3	65.8
CTCC	55.7	61.5	66.5	66.8	64.6	65.2	56.3	46.6	61.6	64.3	43.7	57.7
Ours	62.7	71.9	76.3	72.6	75.1	73.9	70.3	60.8	74.8	72.2	61.4	72.2

実験

- Loss関数重みに関する検証

$$V(P_g^\alpha, T_g^\alpha, T_d^\alpha, P_d^\alpha) \equiv \lambda_{con}^\alpha \sum_{x_t^\alpha = g_t^\alpha(z^\alpha)} v_1(x_t^\alpha) \cdot v_2(x_t^\alpha) - L_{clf}(\delta_h^\alpha, \delta_h^\beta),$$

Table 6. The variation of accuracy against parameter λ_{con}^α

λ_{con}^α	ar→cl	ar→pr	ar→rw	cl→ar	cl→pr	cl→rw
0.001	59.3	68.5	73.3	65.7	68.3	69.3
0.005	61.6	70.3	75.7	70.6	74.6	71.1
0.01	62.7	71.9	76.3	72.6	75.1	73.9
0.02	62.1	71.0	74.7	72.1	76.1	72.8
0.1	53.0	64.8	66.1	60.4	60.4	63.5

- 学習データに関する検証

➤ source/target domain以外のデータは2N程度でよい

Table 7. The variation of accuracy against number of supplementary samples

Num	ar→cl	ar→pr	ar→rw	cl→ar	cl→pr	cl→rw
0.8N	60.3	67.5	73.4	68.8	67.0	70.7
N	61.3	70.7	73.6	70.3	73.2	71.0
1.6N	62.5	71.5	76.0	71.5	74.3	73.5
2N	62.7	71.9	76.3	72.6	75.1	73.9
4N	62.7	71.9	76.3	72.7	75.1	73.9

まとめ

- zero-shot domain adaptationタスクについて、target domain画像を生成する手法を提案した
- 学習したdomain shiftを生成に適用すること、Co-training classifierにより、target domain画像の生成に制約をかけることで、性能を向上する
- Co-training classifierでは、consistency lossを活用し、supervisory signalを作り出すことで、学習に制約をかけた
- 本提案手法は、物体認識やセグメンテーションにも適用可能
- target domainのデータがないことは、実利用する際によくある課題のため、参加になった